

CREMA-D + RAVDESS 멀티모달 연구 진행 보고

설계서·진행문서·실험 산출물 교차검증 기반 상세 발표자료
(기준일: 2026-02-24)

발표 목차

- I. 연구 맥락: 문제정의, KPI, 데이터/분할 프로토콜
- II. 방법론: 전처리/학습 이론, 세부 설정값, 코드 적용 위치
- III. 단계별 실행: Phase-1/2/3/3.5의 가설-방법-결과-인사이트
- IV. 종합 분석: 성능 추세, ablation, 설계 대비 구현 현황
- V. 의사결정: 0.7 달성 해석과 0.9 전환 로드맵

I. 연구 맥락

문제정의, 연구질문, KPI, 데이터/평가 프로토콜

연구 배경과 문제 정의

- **멀티모달 관점에서 해결해야 했던 핵심 문제**
 - 감정 단서는 음성(억양/에너지/리듬)과 영상(표정/동작/시선)에 분산되어 단일모달이 취약합니다.
 - CREMA-D/RAVDESS 간 도메인 차이로 cross-domain 성능 붕괴가 반복적으로 관찰되었습니다.
 - 그래서 본 연구는 main 향상과 cross 회복을 동시에 달성하는 이중 KPI 구조로 운영되었습니다.

핵심 KPI 스냅샷

0.7 트랙(현재)

0.7099

양상블 기준 달성, 단일모델 0.6992

0.9 트랙 격차

+0.2008

단일목표 0.9 대비 부족분

Cross 양방향 최고

0.3207 / 0.3187

v8 hubert + CORAL

연구 데이터셋 규모와 모집단

항목	수치	해석
전체 샘플	11,762	CREMA-D + RAVDESS 전체
CREMA-D	7,442	배우 91, 감정 발화 중심
RAVDESS	4,320	배우 24, audio/video 포함
Common-6	10,610	공통 라벨 정합 후 실험 가능 데이터
멀티모달 AV(Common-6)	8,498	주 학습/평가셋
RAVDESS AO(Common-6)	1,056	오디오 보조 비교셋

라벨 분포(Emotion Common-6)

라벨	샘플 수	비율(%)
angry	1,847	17.41
disgust	1,847	17.41
fearful	1,847	17.41
happy	1,847	17.41
neutral	1,375	12.96
sad	1,847	17.41

main 평가 분할 프로토콜 (GroupKFold)

split	rows	groups(actor)	fold counts
all	11762	115	0:2370, 1:2370, 2:2294, 3:2369, 4:2359
crema_d	7442	91	0:1476, 1:1475, 2:1475, 3:1546, 4:1470
ravdess	4320	24	0:900, 1:900, 2:900, 3:900, 4:720

cross 평가 분할 파일(실제 산출물)

파일 경로	라인 수	비고
derived/splits/cross_dataset/test_crema_train_ravdess_common6_av_train.txt	1056	cross split 파일
derived/splits/cross_dataset/test_crema_train_ravdess_common6_av_test.txt	7442	cross split 파일
derived/splits/cross_dataset/train_crema_test_ravdess_common6_av_train.txt	7442	cross split 파일
derived/splits/cross_dataset/train_crema_test_ravdess_common6_av_test.txt	1056	cross split 파일
derived/splits/cross_dataset/test_crema_train_ravdess_common6_train.txt	3168	cross split 파일
derived/splits/cross_dataset/test_crema_train_ravdess_common6_test.txt	7442	cross split 파일
derived/splits/cross_dataset/train_crema_test_ravdess_common6_train.txt	7442	cross split 파일
derived/splits/cross_dataset/train_crema_test_ravdess_common6_test.txt	3168	cross split 파일

pretrained feature cache 실제 생성 결과 (cache_v5_hubert)

항목	값
cache dir	derived/features/cache_v5_hubert
audio backbone	hubert_base
device	auto/cuda
cuda	NVIDIA GeForce RTX 4090
rows(ok/fail)	8498 / 0
elapsed_sec	887.4

II. 방법론

전처리·모델·평가를 단계별로 통제해 성능 기여를 분해

전처리 방법론(P-track)

P1 데이터 정합

- common-6 라벨 매핑으로 CREMA-D/RAVDESS 통합
- manifest/split 자동 생성으로 재현성 확보
- AV 중심, AO 보조 비교셋 병행

P2 표현 고도화

- cache_v2: log-mel/delta 통계 특징
- cache_v3: raw 재추출 + pretrained video
- cache_v5: HuBERT 오디오 표현 강화

P3 정합/품질

- main/cross 공통 규약으로 비교 가능성 확보
- 캐시 버전 전략으로 변경 영향 분리
- 미완료: ROI/품질플래그/CMVN/SpecAug

P4 연구적 의미

- 입력 표현이 성능 병목임을 실증
- 모델 개선과 입력 개선의 기여 분해 가능
- 0.9 트랙 품질 인지형 전처리의 근거 확보

모델 설계/학습 방법론(A/T-track)

A1 비교군 설계

- B0 -> ML(LR/SVM/RF) -> FP32 멀티태스크
- 모달(audio/video/fusion)별 동시 비교
- 단계별 기준선 유지로 delta 해석 가능

A2 FP32 구조

- dual-encoder + fusion(concat/gated)
- emotion + arousal2/3 multi-head
- 결측 라벨(-1) 마스킹으로 샘플 손실 최소화

A3 학습전략

- CE/Focal + weighted sampler + label smoothing
- cosine scheduler + grad clipping
- gated/wide 확장으로 결합 용량 강화

T/Domain

- audio pretrained: wav2vec2 -> HuBERT
- video pretrained embedding 결합
- cross 적응: CORAL none vs coral 비교

비교/평가/통계 방법론

E1 지표

- 주지표: emotion macro-F1
- 보조: accuracy/OVR-AUC, arousal2/3 MAE
- 불균형에서 accuracy 편향 보정

E2 통제

- 동일 분할·라벨·지표 유지
- 변수(전처리/모델/학습) 단계별 분리
- main/cross 동시 관찰

E3 통계 검증

- phase2 pairwise bootstrap CI
- phase3 vs phase2 delta CI
- 유의한 개선/비개선 구간 분리

E4 운영 재현성

- summary/predictions/progress 표준화
- 장시간 무출력 이슈 -> progress.json
- 스크립트 기반 리포트 자동 생성

특징 캐시 체인 상세(무엇을 어디에 적용했는가)

캐시	오디오 백본	성공/전체	장치	생성시간(s)
cache_v2	none	8498 / 8498	-	191.4
cache_v3	none	8497 / 8498	-	2420.0
cache_v4(wav2vec2)	wav2vec2_base	8498 / 8498	-	1781.8
cache_v5_hubert	hubert_base	8498 / 8498	-	887.4

핵심 설정 Traceability 매트릭스

설정/방법	코드/스크립트 적용 위치	무엇이 바뀌었나	결과(요약)
audio_pretrained_backbone=wav2vec2_base	scripts/run_phase35_strong_v1.sh (STEP1), cache_v4	오디오 임베딩을 통계 특징에 추가	v5 main 0.5734
audio_pretrained_backbone=hubert_base	scripts/run_phase35_next_v8_hubert_main.sh (STEP1), cache_v5_hubert	오디오 표현력 향상	v8 단일 0.6992
fusion_type=gated + modality_dropout	scripts/train_fp32_multitask.py (--fusion-type, --modality-dropout-p)	모달 신뢰도 차이를 반영하는 결합	v7 0.6056 -> v8 0.6992
label_smoothing + weighted_sampler	scripts/train_fp32_multitask.py (--label-smoothing, --weighted-sampler)	불균형/과신 문제 완화	v6 0.5985, v7 0.6056
domain_adapt=coral	scripts/train_ml_baselines.py (--domain-adapt coral)	도메인 공분산 정렬	cross 0.3207/0.3187

전처리/표현 개념 이론 + 실제 적용

개념	이론/의도	실제 적용(설정)	상태
log-mel	주파수 축을 지각 스케일로 압축	cache_v2 audio_feature_v2	적용
delta feature	시간 변화율로 억양 변화 포착	cache_v2 d1 통계	적용
pretrained audio embedding	대규모 음성표현 prior 활용	wav2vec2/hubert/wavlm 옵션	적용
pretrained video embedding	표정/장면 표현력 강화	resnet18/resnet34/efficientnet_b0	적용
CMVN / SpecAugment	도메인 편차/과적합 완화	P-track 강한 버전 항목	미완료
ROI/품질플래그	얼굴 검출 품질 기반 신뢰도 반영	quality-aware fusion 입력	미완료

모델/학습 개념 이론 + 실제 적용

개념	핵심 이론	적용 파라미터	적용 위치
Cross-Entropy	클래스 확률 최대화 기본 목적함수	--emotion-loss ce	train_fp32_multitask.py
Focal Loss	쉬운 샘플 가중치 감소, 어려운 샘플 집중	--emotion-loss focal --focal-gamma	train_fp32_multitask.py
Weighted Sampler	불균형 클래스 출현 빈도 보정	--weighted-sampler	train_fp32_multitask.py
Label Smoothing	과신(confidence overfit) 완화	--label-smoothing	train_fp32_multitask.py
Gated Fusion	모달별 신뢰도 가중 결합	--fusion-type gated	train_fp32_multitask.py
Cosine LR	학습률을 주기적으로 완만 감소	CosineAnnealingLR	train_fp32_multitask.py

CORAL 도메인 적응: 개념 -> 구현 -> 결과

개념/이론

- source/target feature covariance 차이를 줄여 도메인 정렬
- 분류기 구조는 유지하고 입력 분포를 보정
- 데이터셋 스타일 차이에 강건한 baseline 목적

구현

- scripts/train_ml_baselines.py
- --domain-adapt none vs coral 비교
- logreg, linear_svm에서 동일 프로토콜 적용

실험 설계

- CREMA->RAVDESS, RAVDESS->CREMA 양방향
- phase2/v3/v5/v8 단계별 반복 측정
- bootstrap 보고서와 함께 해석

결과

- C->R: 0.2288 -> 0.3207
- R->C: 0.0714 -> 0.3187
- 적응 미적용 대비 명확한 개선 확인

v7(wide) vs v8(tune4) 하이퍼파라미터 상세

설정	v7	v8	의미
epochs	24	40	학습 길이
lr	0.0006	0.00045	수렴 속도/안정성
hidden_dim	384	512	표현 용량
emb_dim	192	256	모달 임베딩 크기
dropout	0.3	0.2	과적합 억제
modality_dropout_p	0.15	0.05	모달 강건성
label_smoothing	0.12	0.08	과신 완화
weighted_sampler	True	True	불균형 대응
device	cpu	cuda	실행 환경

실험 파이프라인 상세(무엇을 어디에 어떻게)

단계	실행 스크립트/코드	입력/설정	출력/결과
데이터 정합	scripts/prepare_research_data.py	CREMA-D + RAVDESS, common-6	manifest/splits/summary.json
특징 생성	scripts/prepare_advanced_features.py	cache_v2/v3/v4/v5, pretrained backbone 옵션	derived/features/cache_*/summary.json
ML baseline	scripts/train_ml_baselines.py	logreg/rbf_svm/linear_svm, domain_adapt	phase2/phase35 *_metrics.csv
FP32 multitask	scripts/train_fp32_multitask.py	fusion/loss/sampler/smoothing/hparams	summary.json + predictions.csv
분석/리포트	scripts/analyze_phase*.py	bootstrap + delta 비교	phase*_results.md / *_metrics.csv

III. 단계별 실행 및 검증

각 단계를 가설-방법-비교-인사이트 템플릿으로 정리

단계별 실행 로드맵(요약)

단계	핵심 질문	핵심 방법	대표 성과
Phase-1	기준선은 어디인가?	majority baseline	F1 약 0.05
Phase-2	fusion 이득이 있는가?	ML(audio/video/fusion)	main fusion 0.3950
Phase-3	FP32 multitask 효과는?	dual-encoder	main 하락/cross 일부 개선
v2~v3	표현 고도화 효과는?	cache 개선 + pretrained	main 0.4807
v4~v5	적응으로 cross 회복 가능한가?	CORAL + strong-v1	cross 0.3025/0.2724
v6~v8	0.7 달성 가능한가?	recipe+gated+HuBERT	단일 0.6992/양상블 0.7099

Phase-1(B0): 기준선 확립

연구질문

- 최빈 기준선을 통해 개선폭을 얼마나 신뢰성 있게 해석할 수 있는가?

방법론

- majority baseline 구성
- macro-F1 중심 비교축 고정

비교/평가

- B0 F1 약 0.05
- 후속 단계 delta 비교 anchor 확보

결론/인사이트

- 성능 목표보다 평가 체계의 기준점 확보가 목적
- 이후 개선폭 해석 신뢰성 확보

Phase-2: 멀티모달 기본 성능 검증

연구질문

- 고전 모델에서도 fusion이 일관된 이득을 보이는가?

방법론

- LR/SVM/RF를 audio/video/fusion으로 병렬 비교
- main/cross 양방향 동시 측정
- 동일 프로토콜로 통제

비교/평가

- main F1: audio 0.3671, video 0.2536, fusion 0.3950
- cross C->R fusion 0.2288, R->C fusion 0.0714

결론/인사이트

- main에서는 fusion 이득이 확인
- cross는 방향 비대칭으로 도메인 갭이 핵심 병목

Phase-2 pairwise bootstrap(main)

비교	delta(F1)	95% CI	해석
fusion - audio	+0.0281	[0.0196, 0.0373]	유의
fusion - video	+0.1417	[0.1294, 0.1531]	유의
audio - video	+0.1136	[0.1016, 0.1264]	유의

Phase-3(FP32): 멀티태스크 딥러닝 검증

연구질문

- FP32 구조가 main/cross를 동시에 개선하는가?

방법론

- dual-encoder + multitask
- 결측 라벨 마스킹 처리
- 학습 안정화 recipe 반영

비교/평가

- main F1 0.3775
- cross C->R 0.2865, R->C 0.0705

결론/인사이트

- 구조만으로 main 우세가 자동 보장되지 않음
- 표현/학습/적응을 함께 올려야 함

Phase-3 vs Phase-2(fusion) bootstrap delta

run	delta(F1)	95% CI	n	판정
main	-0.0176	[-0.0257, -0.0085]	8498	유의
cross C->R	+0.0570	[0.0293, 0.0855]	1056	유의
cross R->C	-0.0007	[-0.0068, 0.0059]	7442	불명확

Phase-3.5(v2~v3): 표현 고도화

연구질문

- 입력 표현 강화가 성능 병목을 해소하는가?

방법론

- cache_v2(log-mel/delta)
- cache_v3(pretrained video)
- ML/FP32 병행 비교

비교/평가

- v2 main 최고 0.4205
- v3 main 최고 0.4807
- cross baseline은 일부 붕괴

결론/인사이트

- 표현 개선은 main 성능에 직접 기여
- 적응이 없으면 cross 일반화는 취약

Phase-3.5(v4~v5): 도메인 적응 + strong-v1

연구질문

- CORAL이 cross 붕괴를 회복하는가?

방법론

- same classifier(logreg)에서 none vs coral 비교
- audio pretrained 강화 결합
- main/cross 동시 모니터링

비교/평가

- v5 main 0.5734
- v5+CORAL C->R 0.3025
- v5+CORAL R->C 0.2724

결론/인사이트

- CORAL은 cross 회복에 실효적
- 표현 강화 + 도메인 정렬의 결합이 핵심

Cross-domain ablation (none vs CORAL)

방향	phase2 fusion	v3 baseline	v5 baseline	v5+CORAL	v8+CORAL
CREMA->RAVDESS	0.2288	0.1190	0.1667	0.3025	0.3207
RAVDESS->CREMA	0.0714	0.1066	0.1439	0.2724	0.3187

Phase-3.5(v6~v8): 0.7 구간 진입

연구질문

- 학습전략 고도화 + HuBERT로 0.7 목표에 도달하는가?

방법론

- v6 0.5985
- v7 0.6056
- v8 HuBERT tune + ensemble


비교/평가

- v8 단일 0.6992
- v8 앙상블 0.7099
- cross 최고 0.3207/0.3187

결론/인사이트

- 0.7은 앙상블 기준 달성
- 단일모델은 임계점 근접, 품질/튜닝 고도화 시 상회 가능


Phase-2 모달리티별 성능 비교 (Macro-F1)



해석: main에서는 fusion 우세, cross에서는 방향별로 audio/fusion 우세가 갈리는 도메인 비대칭 확인


Main 성능 추이 (Emotion Macro-F1)

Macro-F1



Phase-2(0.3950) -> v8 단일(0.6992) -> v8 앙상블(0.7099) | 표현+결합+적응의 누적 효과

Cross-domain 성능 비교 (Macro-F1)



v8 최종 cross: C->R 0.3207, R->C 0.3187 | CORAL + HuBERT 결합이 양방향 개선

main 대표 실험의 F1/MAE 추세

stage	macro-F1	delta(prev)	accuracy	arousal2 MAE	arousal3 MAE
Phase-2 fusion	0.3950	-	0.4122	0.2478	0.5875
Phase-3 FP32	0.3775	-0.0175	0.4195	0.2301	0.5868
v2 logreg	0.4205	+0.0430	0.4408	0.2379	0.6095
v3 rbfsvm	0.4807	+0.0602	0.4872	0.2499	0.5883
v5 logreg	0.5734	+0.0927	0.5729	0.2602	0.5538
v6 fp32	0.5985	+0.0251	0.5994	0.2334	0.5516
v7 fp32	0.6056	+0.0071	0.6061	0.2305	0.5604
v8 단일	0.6992	+0.0935	0.6974	0.2264	0.5392
v8 앙상블	0.7099	+0.0107	0.7088	0.2152	0.5223

v8 후보군 상세 비교(상위 8)

실험명	F1	Acc	A2 MAE	장치
fp32_v8_hubert_ensemble_vote3_main_t3_t4	0.7099	0.7088	0.2152	ensemble
fp32_v8_hubert_ensemble_vote3	0.7047	0.7034	0.2272	ensemble
fp32_v8_hubert_gated_wide_tune4	0.6992	0.6974	0.2264	cuda
fp32_v8_hubert_gated_wide_tune2	0.6961	0.6946	0.2272	cuda
fp32_v8_hubert_gated_wide_tune1	0.6950	0.6938	0.2206	cuda
fp32_v8_hubert_gated_wide_tune3	0.6940	0.6933	0.2177	cuda
fp32_v8_hubert_gated_wide_main	0.6913	0.6905	0.2218	cuda
fp32_v7_best_ref	0.6056	0.6061	0.2305	cpu

설계 대비 구현 현황(P/A/T/Domain)

트랙	설계 요구	현재 상태	해석
P-track	ROI/품질플래그 + CMVN/SpecAug	부분 적용	mel/delta/임베딩 반영, quality-aware 전처리 미완료
A-track	boosting + 고급 fusion	부분 적용	LR/SVM/RF/gated 반영, XGB/LGBM/attention-lite 미완료
T-track	pretrained fine-tuning	부분 적용	HuBERT 기반 강화 성공, backbone unfreeze 제한적
Domain	cross 일반화 강화	적용	CORAL로 양방향 cross 일관 개선 확인

IV. 결론과 의사결정

0.7 달성 해석, 0.9 전환 조건, 실행 리스크 관리

목표 트랙 분리: 0.7 vs 0.9

구분	현재 최고	목표	격차	판정
0.7 단일	0.6992	0.7000	+0.0008	근접
0.7 앙상블	0.7099	0.7000	-0.0099	달성
0.9 단일	?	?	?	?
0.9 앙상블	?	?	?	?

0.9 목표 전환 로드맵(설계 기반)

R1 전처리 고도화

- ROI crop + 품질플래그(blur/brightness/success)
- CMVN/SpecAug/loudness norm full pipeline
- quality-aware feature fusion 입력 확장

R2 모델 구조 고도화

- cross-attention-lite 결합 실험
- boosting(XGB/LGBM) classical track 추가
- 가벼운 구조와 성능의 Pareto 탐색

R3 사전학습 파인튜닝

- frozen embedding -> partial unfreeze
- 오디오/비디오 상위 레이어 감정특화 미세조정
- seed 반복으로 분산 관리

R4 도메인 적응 강화

- CORAL beyond: feature-level adaptation
- consistency/self-training 경로 도입
- main + cross + 분산 동시 만족 기준 적용